

6.2 数据集管理工具

概述

LeRobot 提供了一套完整的数据集管理工具（`lerobot-edit-dataset`），支持删除、分割、合并、特征过滤和格式转换等操作，方便对采集的数据集进行后处理。

工具说明

删除特定 Episodes

采集时如果某些 episode 质量不佳（机械臂抖动、任务失败），可以删除：

Code block

```
1  lerobot-edit-dataset \  
2      --repo_id YOUR_HF_USERNAME/my_dataset \  
3      --operation.type delete_episodes \  
4      --operation.episode_indices "[3, 7, 15]" # 删除第 3、7、15 个 episode (从  
      0 开始计数)
```

参数说明

参数	说明
<code>--repo_id</code>	数据集 ID

<code>--operation.type</code>	操作类型： <code>delete_episodes</code>
<code>--operation.episode_indices</code>	要删除的 episode 编号列表

分割数据集

将一个大数据集按比例或按指定索引分割为训练集/测试集：

按比例分割

Code block

```
1  lerobot-edit-dataset \  
2      --repo_id YOUR_HF_USERNAME/my_dataset \  
3      --operation.type split_dataset \  
4      --operation.train_fraction 0.8    # 80% 训练集, 20% 测试集
```

按指定 episode 分割

Code block

```
1  lerobot-edit-dataset \  
2      --repo_id YOUR_HF_USERNAME/my_dataset \  
3      --operation.type split_dataset \  
4      --operation.split_indices "[0, 40]"    # 前 40 个 episode 为训练集
```

合并多个数据集

将多次采集的数据集合并为一个：

Code block

```
1  lerobot-edit-dataset \  
2      --repo_id YOUR_HF_USERNAME/merged_dataset \  
3      --operation.type merge_datasets \  
4      --operation.source_repo_ids '["user/dataset_a", "user/dataset_b",  
    "user/dataset_c"]'
```

使用场景：

- 分批采集数据后合并
 - 合并不同日期采集的数据集
 - 合并不同初始位置的数据集以增加多样性
-

删除特定特征（摄像头/数据通道）

如果数据集中某个摄像头质量不佳或不需要，可以单独删除：

Code block

```
1  # 删除某个摄像头数据  
2  lerobot-edit-dataset \  
3      --repo_id YOUR_HF_USERNAME/my_dataset \  
4      --operation.type remove_features \  
5      --operation.features_to_remove '["observation.images.wrist"]'  
6  
7  # 删除多个特征  
8  lerobot-edit-dataset \  
9      --repo_id YOUR_HF_USERNAME/my_dataset \  
10     --operation.type remove_features \  
11     --operation.features_to_remove '["observation.images.wrist",  
12     "observation.images.head"]'
```

```
11     --operation.features_to_remove '["observation.images.overhead",  
    "observation.depth"]'
```

图像转视频压缩

将帧式图像数据集转换为 MP4 视频格式，大幅减少存储空间：

Code block

```
1  lerobot-edit-dataset \  
2      --repo_id YOUR_HF_USERNAME/my_dataset \  
3      --operation.type convert_to_video \  
4      --operation.fps 60
```

压缩效果参考：

- 图像格式（PNG）：100 个 episode $\times$ 60fps $\times$ 640 $\times$ 480 $\approx$ 5-10 GB
- 视频格式（MP4）：同等内容 $\approx$ 0.5-2 GB（约减少 90%）

数据集可视化

在线可视化（HuggingFace）

上传到 HuggingFace 后，可以在数据集页面直接查看视频回放：

Code block

```
1  https://huggingface.co/datasets/YOUR_HF_USERNAME/my_dataset
```

本地可视化

Code block

```
1  # 启动本地可视化工具
2  lerobot-dataset-viz \
3      --repo_id YOUR_HF_USERNAME/my_dataset \
4      --episode 0  # 查看第 0 个 episode
```

命令行查看数据集信息

Code block

```
1  python -c "
2  from lerobot.common.datasets.lerobot_dataset import LeRobotDataset
3  dataset = LeRobotDataset('YOUR_HF_USERNAME/my_dataset')
4  print(f'Episode 数量: {dataset.num_episodes}')
5  print(f'总帧数: {len(dataset)}')
6  print(f'摄像头: {list(dataset.meta.camera_keys)}')
7  print(f'关节: {dataset.meta.motor_names}')
8  "
```

数据集质量检查

在训练前建议进行以下质量检查：

Code block

```
1  # 1. 统计各 episode 的帧数（帧数异常说明录制出问题）
2  python -c "
```

```
3 from lerobot.common.datasets.lerobot_dataset import LeRobotDataset
4 dataset = LeRobotDataset('local/my_dataset')
5 for i in range(dataset.num_episodes):
6     ep_data = dataset.hf_dataset.filter(lambda x: x['episode_index'] == i)
7     print(f'Episode {i}: {len(ep_data)} 帧')
8
9
10 # 2. 可视化前 5 个 episode 抽查质量
11 for i in $(seq 0 4); do
12     lerobot-dataset-viz --repo_id local/my_dataset --episode $i
13 done
```

参考资料

- [HuggingFace 数据集工具官方文档](#)