

6.3 HuggingFace 数据集上传与管理

概述

将数据集上传到 HuggingFace Hub 后，可以在云端存储和版本管理，并与社区分享，同时也便于在云 GPU 服务器上直接拉取训练。

注册 HuggingFace 账号

1. 访问 huggingface.co 注册免费账号
 2. 进入账号设置，创建访问令牌（Access Token）：
 - 地址：<https://huggingface.co/settings/tokens>
 - 类型选择 **Write**（写入权限）
 - 复制保存 Token
-

配置本地 HuggingFace 登录

Code block

```
1  # 安装 huggingface_hub
2  pip install huggingface_hub
3
4  # 登录 (输入 Token 后按 Enter)
5  huggingface-cli login
6  # 或
7  python -c "from huggingface_hub import login; login()"
```

验证登录：

Code block

```
1  huggingface-cli whoami
2  # 输出用户名说明登录成功
```

采集时直接上传

在 `lerobot-record` 命令中加入 HuggingFace 账号信息即可自动上传：

Code block

```
1  lerobot-record \
2      --robot.type=so101_follower \
3      --robot.port=/dev/ttyACM0 \
4      --teleop.type=so101_leader \
5      --teleop.port=/dev/ttyACM1 \
6      --dataset.repo_id=YOUR_HF_USERNAME/my_dataset \    # 替换为你的 HuggingFace 用
    户名
7      --dataset.num_episodes=50 \
8      --dataset.single_task="任务描述" \
9      --dataset.push_to_hub=true    # 采集完成后自动上传
```

手动上传已有数据集

如果已有本地数据集，可以手动上传：

Code block

```
1 python -c "  
2 from lerobot.common.datasets.lerobot_dataset import LeRobotDataset  
3 dataset = LeRobotDataset('local/my_dataset')  
4 dataset.push_to_hub(repo_id='YOUR_HF_USERNAME/my_dataset', private=False)  
5 print('上传完成! ')  
6 "
```

数据集命名规范

命名维度	建议格式	示例
用户名/任务	username/task_description	amy/pick_and_place
包含数量	加入 episode 数	amy/pick_and_place_100eps
包含硬件信息	加入机器人型号	amy/so101_pick_and_place

数据集格式说明

上传的 LeRobot 数据集包含以下结构：

Code block

```
1 HuggingFace 数据集仓库：
```

```
2  |— meta/
3  |   |— info.json          # 元数据：关节名称、摄像头名称、FPS、总帧数等
4  |— data/
5  |   |— chunk-000/
6  |       |— episode_000000.parquet    # 时间序列数据（关节角度、时间戳）
7  |       |— ...
8  |— videos/
9  |   |— chunk-000/
10 |       |— observation.images.overhead_episode_000000.mp4
11 |       |— observation.images.wrist_episode_000000.mp4
```

Parquet 文件内容示例：

字段	说明
timestamp	时间戳（秒）
observation.state	关节角度（6维向量）
action	动作指令（6维向量）
episode_index	episode 编号
frame_index	帧编号

从 HuggingFace 下载数据集

Code block

```
1  from lerobot.common.datasets.lerobot_dataset import LeRobotDataset
2
3  # 下载并加载数据集
4  dataset = LeRobotDataset("lerobot/aloha_mobile_cabinet")
5
6  # 查看数据集信息
```

```
7 print(f"Episodes: {dataset.num_episodes}")
8 print(f"Total frames: {len(dataset)}")
9 print(f"Robot type: {dataset.meta.robot_type}")
10
11 # 访问某一帧数据
12 frame = dataset[0]
13 print(frame.keys()) # dict_keys(['observation', 'action', ...])
```

查看社区公开数据集

LeRobot 社区提供了大量公开数据集：

Code block

```
1 # 搜索 SO-101 相关数据集
2 from huggingface_hub import HfApi
3 api = HfApi()
4 datasets = api.list_datasets(search="so101", task_categories=["robotics"])
5 for ds in datasets:
6     print(ds.id)
```

推荐公开数据集：

- [lerobot](#) - HuggingFace 官方数据集合集
- 社区成员分享的 SO-101 数据集（在 HuggingFace 搜索 `so101`）

数据集版本管理

HuggingFace Hub 使用 Git LFS 进行版本管理：

Code block

```
1  # 查看数据集历史版本
2  huggingface-cli repo-info YOUR_HF_USERNAME/my_dataset
3
4  # 下载特定版本
5  dataset = LeRobotDataset(
6      "YOUR_HF_USERNAME/my_dataset",
7      revision="v1.0" # 指定版本号
8  )
```

参考资料

- [HuggingFace Hub 文档](#)
- [LeRobot 数据集官方文档](#)